

Implementação Perceptron

Daniel Petrucio
Sistemas Inteligentes
Universidade Federal de Santa Catarina

Abstract—Este artigo apresenta a implementação do Perceptron utilizando LaTeX, explorando técnicas para lidar com problemas multiclases através do método Um contra Todos. O estudo utiliza validação cruzada para avaliar a eficácia do modelo em bases de dados sintéticas, incluindo uma linearmente separável e outra não linearmente separável. Resultados detalhados são discutidos, destacando a acurácia alcançada e o comportamento do algoritmo ao longo das épocas de treinamento. Além disso, são analisadas as limitações do Perceptron em problemas complexos e não linearmente separáveis. Este trabalho contribui para a compreensão prática do Perceptron como um classificador de camada única em diferentes contextos de aplicação.

Index Terms—Perceptron, machine learning, IEEE, LaTeX, artigo

I. INTRODUÇÃO

Implementação de um perceptron de uma camada para classificar problemas binários multiclases, utilizando o método um contra todos para lidar com as multiclases e validação cruzada para validação.

II. UM CONTRA TODOS

Para que um Perceptron de apenas uma camada consiga classificar problemas multiclases, foi necessário usar o método Um contra todos, o qual realiza a classificação binária de cada uma das classes e determina a classe final com base na maior pontuação obtida entre os classificadores individuais.

III. VALIDAÇÃO CRUZADA

O modelo de validação usado foi a validação cruzada, com $k = 10$

IV. BASES DE DADOS

São geradas duas bases de dados, sinteticamente, uma linearmente separável e outra não linearmente separável

A. Base Linearmente Separável

Para a base 1 linearmente separável, temos 1000 elementos, 4 características e 3 classes.(Fig. 1)

B. Base Não Linearmente Separável

Para a base 2 temos 1000 elementos, 7 características e 3 classes(Fig. 2)

V. AVALIAÇÃO

Para avaliar qual foi o melhor modelo de treinamento, considere qual método obtém a melhor acurácia em menos épocas




Fig. 1. Representação gráfica da Base 1.




Fig. 2. Representação gráfica da Base 2.

VI. TREINAMENTO E TESTE

A. Base 1

No treinamento da base 1 (Fig. 3), obtivemos um desvio padrão: 0.0033075371594305887 e uma média: 0.508010101010101. Considerando as métricas de avaliação consideremos o modelo 7 como o mais eficiente, tendo uma acurácia : 0.51 em 266 épocas

B. Base 2

No treinamento da base 1 (Fig. 4), obtivemos um desvio padrão: 0.11223888840212458 e uma média: 0.19816717181922275. Considerando as métricas de avaliação consideremos o modelo 1 como o mais eficiente, tendo uma acurácia :0.38613861386138615 em 1000 épocas

VII. DESEMPENHO

Por o perceptron ser um classificador binário e de apenas uma camada, ele não apresenta um bom desempenho em problemas multiclases e que não estejam linearmente separáveis, por criar retas que fazem a separação das classes

forma eficiente

Convergência Base 1

| Classe 0 | Classe 1 | Classe 2 | Acurácia |
|------------|-------------|-------------|----------|
| 191 épocas | 1000 épocas | 637 épocas | 0.5000 |
| 274 épocas | 1000 épocas | 849 épocas | 0.5100 |
| 266 épocas | 1000 épocas | 1000 épocas | 0.5100 |
| 189 épocas | 1000 épocas | 648 épocas | 0.5100 |
| 187 épocas | 1000 épocas | 549 épocas | 0.5100 |
| 232 épocas | 1000 épocas | 736 épocas | 0.5100 |
| 297 épocas | 1000 épocas | 613 épocas | 0.5100 |
| 214 épocas | 1000 épocas | 395 épocas | 0.5100 |
| 370 épocas | 1000 épocas | 430 épocas | 0.5051 |
| 185 épocas | 1000 épocas | 651 épocas | 0.5051 |

Fig. 3. Representação gráfica da Base 1.




Fig. 6. Retas da Base 2.

Convergência Base 2

| Classe 0 | Classe 1 | Classe 2 | Acurácia |
|----------|----------|----------|----------|
| 1000 | 1000 | 1000 | 0.3861 |
| 1000 | 1000 | 1000 | 0.0693 |
| 1000 | 1000 | 1000 | 0.0693 |
| 1000 | 1000 | 1000 | 0.1584 |
| 1000 | 1000 | 1000 | 0.1900 |
| 1000 | 1000 | 1000 | 0.1200 |
| 1000 | 1000 | 1000 | 0.2300 |
| 1000 | 1000 | 1000 | 0.3535 |
| 1000 | 1000 | 1000 | 0.3131 |
| 1000 | 1000 | 1000 | 0.0918 |

Fig. 4. Representação gráfica da Base 1.

REFERENCES

- [1] <https://hub.asimov.academy/tutorial/o-que-e-o-algoritmo-perceptron/>
- [2] <https://machinelearningmastery.com/implement-perceptron-algorithm-scratch-python/>
- [3] <https://medium.com/@avijit.bhattacharjee1996/implementing-k-fold-cross-validation-from-scratch-in-python-ae413b41c80d>

A. Retas Geradas Para Base 1

Para a base um apenas uma das retas de fato consegue fazer uma separação na base de dados, enquanto as outras estão completamente fora dela, como visto na figura 5




Fig. 5. Retas da Base 1.

B. Retas Geradas Para Base 2

Para a base 2 apesar de ter duas retas compreendidas dentro da base (Fig. 6) ainda assim tem baixo poder de classificar de